

Smartphone-Specific Anomaly Detection and Enhanced MLLM Reasoning Using Generative AI-Driven Data Augmentation

Data Analysis Capstone Design 2025-2 - Final

2025. 12. 15. Mon.

KyungHee University IMSE

학사과정 장준필, 이 찬

Contents

1. Background & Problem
2. Project Idea
3. Methodology
4. Results & Analysis
5. Conclusion


1. Background & Problem

1. Introduction

• Background

- 비대면, 이미지 중심의 중고거래 플랫폼 급성장
- 카테고리 다양화 및 거래량 ↑ → 검수 물량 증가로 일관된 기준 필요
- But, 플랫폼마다 품질 기준 상이 or 공개 X


95점 추천 상품 ⑦



[Kream 플랫폼의 품질점수]

• Problem

- 중고거래 플랫폼 관점: 품질 판단의 주관성, 수작업 검사 시간 및 비용 ↑
- 구매자 관점: 사진만으로는 제품의 품질 상태를 확인하기 어려워 신뢰성 ↓



[당근마켓]

2. Project Idea

1. Project Introduction

- **Proposed Project**

- 중고거래 플랫폼의 주관적 수작업 검사↓
- 구매자의 신뢰도 확보를 위한 상품 이미지의 이상 여부, 위치, 결함 정도 제시
- 일관된 품질 평가 보고서 및 시스템 구축
- + Domain(SmartPhone) 설정


- **Project main Idea**

- zero-shot anomaly dection 모델 구축 → 중고 이미지의 이상 여부, 위치, 결함 정도를 제시
- Multimodal LLMs 활용 → 중고 이미지의 이상 여부, 위치, 결함 정보를 기반으로 품질 보고서 작성
- 특정 Domain의 Anomaly Dataset 구축

3. Methodology

1. Anomaly Detection Model Selection

- Zero-shot Anomaly Detection Model with MLLMs
 - MLLMs 을 활용한 Zero-shot Anomaly Detection model 선정
 - 이상치 탐지 데이터 불균형 및 부족 문제 해결 가능성 제시
 - 참고 논문: Towards Zero-Shot Anomaly Detection and Reasoning with MLLMs (CVPR 2025 - Highlight Paper)



3. Methodology

2. Anomaly dataset 구축

• Smartphone normal / abnormal Dataset 구축

- 공개 데이터셋 수집 + 추가 수집 데이터
- Train / Test Split → 기종에 따른 구별 (Case 구별, zero-shot 성능 평가를 위해)

Split	Class	Data Source	Description	Images	Total
Train	Normal	Real	Coupang Reviews (New Products)	337	587
	Normal	Generative	Gemini 3 (Hard Negatives)	250	
	Abnormal	Real	Used Markets & Benchmarks (Cracks, Dents)	262	462
	Abnormal	Generative	Gemini 3 (Fine Scratches, Burn-in)	200	
Validation	Normal	Real	Coupang Reviews	87	147
	Normal	Generative	Gemini 3	60	
	Abnormal	Real	Used Markets & Benchmarks	66	116
	Abnormal	Generative	Gemini 3	50	
Test	Normal	Real	2024-2025 New Models (Real World)	100	100
	Normal	Generative	—	0	
	Abnormal	Real	2024-2025 New Models (Real World)	294	294
	Abnormal	Generative	—	0	
Total	—	—	—	—	1706

Smartphone Anomaly Dataset Table



Real data(left) / 생성형 AI data(right)


3. Methodology

7

3. Training Anomaly Detection Model

- 학습을 위한 모델 구조 설계

- 논문의 모델 구조 및 가중치를 활용하여 학습 진행 (Visual Encoder ~ LLM Projecter전)
- Visual Encoder → Adaptor → LTFM → VT Selector => 분리된 각 구조를 연결하여 모델 설계
- 출력: Anomaly score, Anomaly 여부(0/1), Heatmap based anomaly score



3. Methodology

4. Results & Analysis before training

- 학습 전 성능 파악
 - 논문의 가중치만을 활용한 Test set 적용 → Metrics, heatmap 결과 분석 및 파악
→ 큰 손상에 대한 파악은 어느정도 가능
 - 오분류된 Image Dataset 분석 및 파악 → 잔기스 및 빛 번짐에 따른 오분류 발생 → 학습 필요성


Confusion Matrix

	Pred 0	Pred 1
Actual 0	92	8
Actual 1	72	222


True label

Predicted label

Confusion Matrix Results



Metrics



오분류된 Dataset Sample

3. Methodology

5. Training Model with smartphone anomaly datasets

- 기존 학습에서의 문제점: Overfitting 및 성능 하락
- 1) 성능 개선 및 과적합 방지를 위한 Hyperparameter tuning
 - optimizer: AdamW
 - loss function: Binary Cross Entropy (BCE)
 - Batch size 증가 → 조금 더 안정적인 gradient 유도
 - Learning Rate 감소 ($2e^{-4}$)
 - Weight decay 감소 ($5e^{-4}$) → L2 normalization 강도 증가
 - 기타: Dropout, Scheduler 등의 다양한 실험을 통해 가장 높은 일반화 성능을 내는 Hyperparameter 선정

3. Methodology

5. Training Model with smartphone anomaly datasets

- 2) Threshold 결정 기준 선정


- Before: validation set에서 F1 score가 가장 높은 threshold 선택
- After: Pareto Filtering(Precision, Recall, F1) + $\min(\text{Precision}, \text{Recall})$
 - 3개 지표 모두 더 낮은 threshold들은 전부 제거해서 후보를 축소한 후,
Pareto 후보들 중 $\min(\text{Precision}, \text{Recall})$ 이 가장 큰 것을 선택
- 즉, Precision과 Recall 둘 중 하나를 너무 낮게 하지 않도록 하기 위해 두 지표가 균형 있게 높은 해를 선택

3. Methodology

11

5. Training Model with smartphone anomaly datasets

- 2) Threshold 결정 기준 선정



	Criterion	Precision (%)	<u>Recall</u> (%)	F1 (%)	P-R (%)
0	Best F1	100.00	98.28	99.13	1.72
1	Pareto + min(<u>P,R</u>)	98.29	99.14	98.71	0.85

4. Results & Analysis

1. Fine tuning을 통한 성능 향상 확인

- **(Base) Pretrained Model**

- 도메인 적응 전 성능 기준점 설정
- Threshold=0.6070 / Accuracy: 79.70% / Precision: 96.52% / Recall: 75.51% / F1-score: 84.73%

- **Fine Tuning Model without Generative AI Image**

- 생성형 데이터가 희소 결함 학습에 기여하는 효과 검증
- Threshold=0.8750 / Accuracy: 82.99% / Precision: 97.89% / Recall: 78.91% / F1-score: 87.38%


- **Fine Tuning Model with Generative AI Image**

- LTFM 모듈의 일반적인 도메인 적응 효과 확인
- Threshold=0.4250 / Accuracy: 84.26% / Precision: 97.54% / Recall: 80.95% / F1-score: 88.48%


4. Results & Analysis

2. Fine tuning effect analysis

- (Base) Pretrained Model
 - 정밀도(96.52%)는 높았으나 재현율(75.51%)이 상대적으로 낮게 나타남
 - 도메인 특화 미세 결함을 정상으로 오분류하는 경향이 강하게 나타남
- Fine Tuning Model without Generative AI Image
 - 정밀도와 재현율 모두 상승하였으며 f1-score가 87.38%로 상승
 - 도메인 적응 학습을 통해 미세 결함에 대한 민감도를 일부 높임
- Fine Tuning Model with Generative AI Image
 - 모든 시나리오 중 가장 우수한 성능 달성
 - 생성형 데이터가 고난도 탐지 유형을 모델에게 효과적으로 학습시킴



FN: 72 (Missed Anomaly)




FN: 56 (Reduction ↓)

4. Results & Analysis


2. Fine tuning effect analysis



(Base) Pretrained Model에서 False Negative인 Case



Base Model에서 False Negative였던 Case의 Fine-Tuning (Real + GenAI) 예측 결과



4. Results & Analysis

3. Misclassification data Analysis

- 일부 test case에서 여전히 오분류가 발생하는 원인을 분석
 - 1) 학습 데이터의 부재한 결함 유형
 - 학습 데이터에 포함되지 않은 결함 유형은 인식하지 못하는 한계 존재
 - 2) 이미지 품질 저하로 인한 특징 소실
 - 입력 이미지의 해상도가 낮거나 초점이 맞지 않은 경우, 탐지 성능의 저하 발생
 - 3) 기능적 결함과 시각적 결함의 괴리
 - 액정 패널의 고장으로 인해 화면의 일부만 켜지는 형태의 결함 인식 부재

Anomaly Map
Pred Score: 0.0002



Anomaly Map
Pred Score: 0.0292



Anomaly Map
Pred Score: 0.0028



4. Results & Analysis

4. Connect MLLM & Generate Quality Report

- 학습 이후 MLLM과의 연결을 통해 품질 보고서 생성 시도 및 실험 진행
- 1) 프롬프트문 설계: System Prompt - 모델의 역할 지정 및 출력 형식 고정

System Prompt

“You are an expert visual quality inspector for smartphone front screens. Given an input image (and optionally anomaly-related metadata), you must write a structured quality report in Korean with the following format:

First line: “품질 보고서”

Second line: “Anomaly Score: [숫자]”

Third line: “Model prediction: [Normal/Abnormal]”

Section 1: “1. 종합 평가” — 전체적인 외관 상태와 주요 결함을 2-4문장으로 요약

Section 2: “2. 결함 위치 및 유형” — 번호를 붙여 결함 위치, 형태, 영향도를 기술

Use concise, formal Korean. Describe only defects that can be reasonably supported by the visual evidence or metadata.

4. Results & Analysis

4. Connect MLLM & Generate Quality Report

- 1) 프롬프트문 설계: User Prompt - 이미지와 이상 점수, 모델 예측과 함께 이미지를 관찰해 결함을 찾고 구체적인 서술

User Prompt

“You are given: A smartphone front-screen image. An anomaly score and model prediction from an anomaly detection model.

Use the following metadata: Anomaly Score: {anomaly_score} Model prediction: {model_prediction}

Instructions: Inspect the entire front screen surface and identify any defects you can observe from the image. Describe only defects that are visually plausible based on the image and metadata. Be explicit about where the defect is located (e.g., relative position on the screen) and what type of surface damage it appears to be (scratch, spot, crack, etc.).

Now write the quality report in Korean in the following exact format:

품질 보고서

Anomaly Score: {anomaly_score}

Model Prediction: {model_prediction}

1. 종합 평가 (2-4문장으로 전체적인 외관 상태와 주요 결함을 요약한다.)

2. 결함 위치 및 유형

[결함 #1] ...

[결함 #2] ... (필요한 경우에만).

4. Results & Analysis

4. Connect MLLM & Generate Quality Report

- 1) 프롬프트문 설계: ROI of System Prompt
- Bounding box가 포함된 image와 only-image와의 품질 보고서의 비교를 위해 추가한 프롬프트문
- ROI: 이상 탐지 모델이 잠재적 결함 후보로 판단한 영역을 의미 -> 해당 내부를 더 꼼꼼하게 관찰하는 문단 추가

but, 최종적으로는 여전히 이미지와 메타데이터로부터 합리적인 결함만을 보고서에 포함하도록 설계

ROI of System Prompt

Additionally, some rectangular bounding boxes are overlaid on the image. These bounding boxes indicate regions of interest (ROI) where the anomaly model suspects potential defects. Carefully and thoroughly inspect the inside of each ROI, as these areas are statistically more likely to contain subtle defects. However, still report only those defects that you judge as visually plausible based on the image; if an ROI appears normal (e.g., only reflection or lighting), you may consider it as “no defect” in your final description.

4. Results & Analysis

SmartPhone with bounding box



Anomaly Score: 0.9989
Prediction: Abnormal

System prompt

You are an expert visual quality inspector for smartphone front screens.

Given an input image (and optionally anomaly-related metadata), you must write a structured quality report in Korean with the following format:

First line: "품질 보고서"

Second line: "Anomaly Score: [숫자]"

Third line: "Model prediction: [Normal/Abnormal]"

Section 1: "1. 종합 평가" — 전체적인 외관 상태와 주요 결함을 2-4문장으로 요약

Section 2: "2. 결함 위치 및 유형" — 번호를 붙여 결함 위치, 형태, 영향도를 기술

Use concise, formal Korean. Describe only defects that can be reasonably supported by the visual evidence or metadata.

User prompt

You are given: A smartphone front-screen image. An anomaly score and model prediction from an anomaly detection model.

Use the following metadata: Anomaly Score: (anomaly_score) Model prediction: (model_prediction) Instructions: Inspect the entire front screen surface and identify any defects you can observe from the image and metadata. Be explicit about where the defect is located (e.g., relative position on the screen) and what type of surface damage it appears to be (scratch, spot, crack, etc.).

Now write the quality report in Korean in the following exact format:

품질 보고서

Anomaly Score: (anomaly_score)

Model Prediction: (model_prediction)

1. 종합 평가 (2-4문장으로 전체적인 외관 상태와 주요 결함을 요약한다.)

2. 결함 위치 및 유형

[결함 #1] ...

[결함 #2] ... (필요한 경우에만)

Additionally, some rectangular bounding boxes are overlaid on the image. These bounding boxes indicate regions of interest (ROI) where the anomaly model suspects potential defects. Carefully and thoroughly inspect the inside of each ROI, as these areas are statistically more likely to contain subtle defects. However, still report only those defects that you judge as visually plausible based on the image; if an ROI appears normal (e.g., only reflection or lighting), you may consider it as "no defect" in your final description.

System prompt

You are an expert visual quality inspector for smartphone front screens.

Given an input image (and optionally anomaly-related metadata), you must write a structured quality report in Korean with the following format:

First line: "품질 보고서"

Second line: "Anomaly Score: [숫자]"

Third line: "Model prediction: [Normal/Abnormal]"

Section 1: "1. 종합 평가" — 전체적인 외관 상태와 주요 결함을 2-4문장으로 요약

Section 2: "2. 결함 위치 및 유형" — 번호를 붙여 결함 위치, 형태, 영향도를 기술

Use concise, formal Korean. Describe only defects that can be reasonably supported by the visual evidence or metadata.

User prompt

You are given: A smartphone front-screen image. An anomaly score and model prediction from an anomaly detection model.

Use the following metadata: Anomaly Score: (anomaly_score) Model prediction: (model_prediction) Instructions: Inspect the entire front screen surface and identify any defects you can observe from the image. Describe only defects that are visually plausible based on the image and metadata. Be explicit about where the defect is located (e.g., relative position on the screen) and what type of surface damage it appears to be (scratch, spot, crack, etc.).

Now write the quality report in Korean in the following exact format:

품질 보고서

Anomaly Score: (anomaly_score)

Model Prediction: (model_prediction)

1. 종합 평가 (2-4문장으로 전체적인 외관 상태와 주요 결함을 요약한다.)

2. 결함 위치 및 유형

[결함 #1] ...

[결함 #2] ... (필요한 경우에만)

품질 보고서

Anomaly Score: 0.9989

Model Prediction: Abnormal

1. 종합 평가

본 이미지는 이상 점수 0.9989로, 기준치를 크게 상회하여 전면부에 복수의 외관 결함이 존재하는 단말기로 판단된다. 모델이 제시한 바운딩 박스(의심 구역)를 기준으로 정밀 관찰한 결과, 전면 좌측 중단부에서 두드러진 주요 표면 손상 1건과 화면 중앙 부근에서 일반 육안 검사에서는 놓치기 쉬운 가느다란 "ㄱ"형 미세 스크래치 1건이 실제 결함으로 확인되었다. 일부 바운딩 박스 영역은 조명 반사나 이미지 노이즈로 판단되어 결함에서 제외되었으나, 주요 및 미세 결함이 동시에 존재한다는 점에서 무결점(A급) 출하 기준에는 부적합하며 8급 또는 리퍼/리워크 대상으로 분류하는 것이 타당하다. 특히 좌측 손상은 한눈에 보이는 수준으로 외관 신뢰도를 저하시킬 수 있고, 중앙부 미세 스크래치는 프리미엄 단말기 가격의 기대 수준을 고려할 때 추가 관리가 필요한 요소로 평가된다.

2. 결함 위치 및 유형

2-1. [결함 #1] 좌측 중단부 표면 손상 (주요 결함)

- 위치: 전면 화면의 좌측 중단부
- 형태: 세로 방향으로 비교적 길게 이어진 긁힘/찍힘 흔적 손상
- 특성: 주변 대비 밝기와 질감이 일정하게 깨져 있으며, 조명 각도 변화에도 패턴이 유지되어 실제 물리적 손상으로 판단된다. 일반 사용자가 육안으로도 인지 가능한 수준의 결함으로, 외관 품질 평가 시 주요 감점 요인에 해당한다.
- 영향도: 미관 저하가 뚜렷하고 장기 사용 시 미세 균열 확산 가능성도 있어 프리미엄-무결점 등급에는 적합하지 않다.

2-2. [결함 #2] 화면 중앙부 "ㄱ"형 미세 스크래치 (세부 결함)

- 위치: 화면 정중앙에서 약간 오른쪽 영역
- 형태: 짧은 가로 방향 "ㄱ" 모양의 헤어라인 스크래치
- 특성: 크기가 작고 조명 조건에 따라 희미하게 보이지만, 바운딩 박스를 기준으로 확대 관찰했을 때 연속적인 선형 손상이 확인된다. 일반적인 육안-기본 촬영만으로는 간과되기 쉬운 미세 결함에 해당한다.
- 영향도: 기능에는 직접적 영향은 없으나, 고가 단말기의 외관 완성도와 고객 만족도에 부정적 요소로 작용할 수 있어 "미세 스크래치 존재" 항목으로 별도 기록이 필요하다.

2-3. [기타 의심 영역] 이상 없음으로 판정

- 내용: 상단 및 하단 일부 바운딩 박스 구역은 확대 관찰 결과 조명 반사, 배경 질감, 이미지 노이즈로 확인되어 실질적인 결함으로 보기는 어렵다. 이는 모델이 넓은 범위의 의심 후보를 제시하고, LLM 기반 보고서에서 최종적으로 결함 여부를 선택·정제하는 데 의미가 있음을 보여준다.

📄 📏 🔍 🔄 🗑️ ...

ROI-guided version Quality report result

품질 보고서

Anomaly Score: 0.8167

Model Prediction: Abnormal

1. 종합 평가

이미지 관찰 결과, 전면 좌측 중단부에 비교적 큰 표면 손상 1건이 명확히 확인되며, 이로 인해 무결점(A급) 출하 기준에는 부적합할 가능성이 높은 단말기로 판단된다.

2. 결함 위치 및 유형

2-1. [결함 #1] 좌측 중단부 표면 손상 (확인된 주요 결함)

- 위치: 전면 화면의 좌측 중단부
- 형태: 세로 방향으로 비교적 길게 파져 있는 스크래치/마찰 자국
- 특성: 주변 영역에 비해 밝기와 질감이 눈에 띄게 달라 보이며, 한 번 이상 강하게 긁히거나 비벼진 흔적으로 추정된다. 일반 사용자도 쉽게 인지 가능한 수준의 시각적 결함으로, 외관 평가 시 명확한 감점 요소에 해당한다.
- 영향도: 제품의 첫인상과 심리적 품질 인식에 부정적 영향을 줄 수 있으며, 프리미엄급 무결점 출하를 목표로 할 경우 재검도 또는 등급 조정에 필요한 수준으로 평가된다.

📄 📏 🔍 🔄 🗑️ ...

Image-only version Quality report result

4. Results & Analysis

4. Connect MLLM & Generate Quality Report

- 2) 품질 보고서 결과 비교
- **공통점:** 이상 점수 기반 품질 상태를 Abnormal로 판단 + 전면 좌측 큰 손상을 주요 결함으로 기술
- **차이점:** ROI-guided 품질보고서는 중앙부의 희미한 패턴을 시각적으로 타당한 결함으로 판단

SmartPhone with bounding box



Anomaly Score: 0.9989
Prediction: Abnormal

2. 결함 위치 및 유형

2-1. [결함 #1] 좌측 중단부 표면 손상 (확인된 주요 결함)

- 위치: 전면 화면의 좌측 중앙부
- 형태: 세로 방향으로 비교적 길게 퍼져 있는 스크래치/마찰 자국
- 특성: 주변 영역에 비해 밝기와 질감이 눈에 띄게 달라 보이며, 한 번 이상 강하게 긁히거나 비벼진 흔적으로 추정된다. 일반 사용자도 쉽게 인지 가능한 수준의 시각적 결함으로, 외관 평가 시 명확한 감점 요소에 해당한다.
- 영향도: 제품의 첫인상과 심리적 품질 인식에 부정적 영향을 줄 수 있으며, 프리미엄급 무결점 출하를 목표로 할 경우 재검토 또는 등급 조정이 필요한 수준으로 평가된다.



Image-only version Quality report result

2-2. [결함 #2] 화면 중앙부 “-”형 미세 스크래치 (세부 결함)

- 위치: 화면 정중앙에서 약간 오른쪽 영역
- 형태: 짧은 가로 방향 “-” 모양의 헤어라인 스크래치
- 특성: 크기가 작고 조명 조건에 따라 희미하게 보이지만, 바운딩 박스를 기준으로 확대 관찰했을 때 연속적인 선형 손상이 확인된다. 일반적인 육안·기본 촬영만으로는 간과되기 쉬운 미세 결함에 해당한다.
- 영향도: 기능에는 직접적 영향은 없으나, 고가 단말기의 외관 완성도와 고객 만족도에 부정적 요소로 작용할 수 있어 “미세 스크래치 존재” 항목으로 별도 기록이 필요하다.

2-3. [기타 의심 영역] 이상 없음으로 판정

- 내용: 상단 및 하단 일부 바운딩 박스 구역은 확대 관찰 결과 조명 반사, 배경 질감, 이미지 노이즈로 확인되어 실질적인 결함으로 보기는 어렵다. 이는 모델이 넓은 범위의 의심 후보를 제시하고, LLM 기반 보고서에서 최종적으로 결함 여부를 선별·정제하는 데 의미가 있음을 보여준다.



ROI-guided version Quality report result

5. Conclusion

요약 및 기대효과

- 생성형 AI 기반 데이터 증강 + 도메인 특화 MLLM(Anomaly-OV, LTFM) fine tuning을 결합해
스마트폰 외관 결함에 대한 설명 가능한 품질 관리 시스템 구현
- 데이터 생성 → 모델 최적화 → 임계값 결정 → 교차 세대 일반화 검증까지 실무에 적용 가능한 End-to-End 파이프라인 제시
- 1) 데이터 희소성 및 불균형 문제 해결
 - Gemini 3로 미세 기스, 번인, 미세 찍힘 등 희소 결함 합성 데이터 대량 생성
 - Hard Negative 정상 샘플까지 포함해 결함 다양성 확장 + 클래스 불균형 완화
 - 초기 데이터가 적은 Cold Start 환경에서도 바로 적용 가능한 범용 파이프라인 제시

5. Conclusion

요약 및 기대효과

- 2) 설명 가능한 지능형 QC 성능 향상
 - 스마트폰 도메인에 맞게 LTFM을 파인튜닝해 F1-score 88.48% 달성
 - 결함 위치에 대한 Bounding Box + 시각적 근거(Visual Rationale) 제공
 - 어디에 어떤 결함이 있는지를 자연어로 설명해 인간 검사관의 신뢰도·판정 일관성 향상
- 3) 도메인 특화 임계값(τ) 설계를 통한 검수 정책 반영 가능
 - Pareto Filtering + max-min(P, R) 기준으로 임계값을 설정해 균형을 맞추는 강건한 결정 경계 확보
 - 재현율 99% 이상 등 기업별 검수 정책을 그대로 반영 가능한 사용자 맞춤형 기준 제시

5. Conclusion

요약 및 기대효과

- 4) 교차 세대(Cross-Generation) 일반화 확보

- train: 2017~2023년 기종 / test: 2024~2025년 기종으로 분리 평가
- 새로운 디자인 및 재질의 신제품에서도 성능 유지 → 연간 재학습 부담 및 유지보수 비용 절감
- 스마트폰을 넘어 세대 교체 주기가 빠른 제품군 전반에 적용 가능한 일반화 프레임워크

- 추후 연구 방향

- 생성 결함 데이터의 사실성을 정량 평가하고(도메인 특화 FID 등), 실제 결함과의 분포 차이를 축소하는 연구
- LTFM 탐지 성능을 유지하면서 지식 증류, 양자화 등으로 MLLM을 경량화해 실시간 추론이 가능하도록 하는 연구
- 스마트폰 외관을 넘어 NDT(X-ray, CT), 3D 포인트 클라우드 등 다양한 제조 도메인으로 프레임워크를 확장, 검증 연구

Thank you!

Data Analysis Capstone Design 2025-2 - Final