

〈 2025년 2학기 프로젝트 최종보고서 〉

교과목 명	데이터분석캡스톤디자인		학수번호	SWCON32103
프로젝트 명	Smartphone-Specific Anomaly Detection and Enhanced MLLM Reasoning Using Generative AI-Driven Data Augmentation			
지도교수	이름		소속	이메일
	조명아		소프트웨어융합대학 소프트웨어융합학과	maycho@khu.ac.kr
팀원 (멘티)	이름		학과 (다전공)	이메일
	팀장	장준필	소프트웨어융합학과 (산업경영공학과)	jang17107@khu.ac.kr
	팀원	이찬	소프트웨어융합학과 (산업경영공학과)	chan112500@khu.ac.kr
	팀원			
	팀원			
멘토	이름		소속	이메일
	최원서		모바일앱개발협동조합	dexter07@naver.com

Smartphone-Specific Anomaly Detection and Enhanced MLLM Reasoning Using Generative AI-Driven Data Augmentation

팀원

경희대학교 산업경영공학과 장준필

경희대학교 산업경영공학과 이 찬

요약

최근 멀티모달 대형 언어 모델(MLLM)은 시각적 추론에서 혁신적인 발전을 보였으나, 스마트폰 품질 관리(QC)와 같이 미세 결함(fine-grained anomaly) 탐지가 요구되는 특정 도메인에서는 여전히 한계를 보인다. 본 연구는 이를 극복하기 위해 제로샷 이상 탐지 모델인 Anomaly-OneVision(Anomaly-OV)의 Look-Twice Feature Matching(LTFM) 모듈을 스마트폰 도메인에 특화하여 파인튜닝하는 기법을 제안한다. 특히 Gemini 3 를 활용한 데이터 증강을 통해 미세 기스나 번인(burn-in)과 같은 희소 결함 데이터의 불균형 문제를 해결하였으며, 기종 출시 연도를 기준으로 학습(2017–2023) 및 평가(2024–2025) 데이터를 분리하여 세대 간 일반화(cross-generation generalization) 성능을 검증하였다. 실험 결과, 생성형 데이터를 포함하여 학습한 모델이 F1-score 88.48%를 기록하며 베이스 모델(84.73%) 및 생성형 data 를 제외한 실데이터 단독 학습 모델(87.38%) 대비 가장 우수한 성능을 입증하였다. 이는 합성 데이터가 미세 이상 패턴 학습에 실질적으로 기여함을 시사하며, 향상된 탐지 성능이 LLM 의 결함 설명 품질 개선으로 이어짐을 확인함으로써, 본 연구의 프레임워크가 스마트폰을 넘어 도메인 특화 결함 데이터 확보가 어려운 다양한 산업 도메인의 품질 관리 자동화에 폭넓게 적용될 수 있는 범용적 가능성을 제시한다.

1. 서론

1.1 연구배경

제조업에서의 시각적 이상 탐지(Visual Anomaly Detection, AD)는 제품의 품질을 보장하는 핵심 공정이다. 최근 딥러닝 기술의 발전으로 지도 학습 기반의 AD 가 널리 사용되고

있으나, 이는 대량의 정상 및 결함 데이터가 필요하다는 한계가 있다. 특히 스마트폰과 같은 소비자 가전 시장에서는 매년 새로운 모델이 출시되며, 미세한 기스나 찍힘, 디스플레이 번인 등 다양한 형태의 결함이 발생하므로, 이를 신속하게 탐지할 수 있는 Anomaly Detection 방법론이 요구된다.

1.2 문제 정의

최근 발표된 Anomaly-OV 는 MLLM 을 활용하여 이미지 내 이상 유무를 판단하고 그 이유를 설명하는 혁신적인 접근법을 제시하였다. 이 모델은 인간의 시각 검사 방식을 모방한 LTFM(Look-Twice Feature Matching) 메커니즘을 통해 의심스러운 시각 토큰을 선별하고 강조한다. 그러나 사전 학습된 Anomaly-OV 모델은 일반적인 산업 데이터셋(MVTec AD, VisA 등)에는 강력하지만, 스마트폰 액정의 미세한 흠집이나 찍힘과 같은 '도메인 특화 미세 결함'을 탐지하는 데 실패하는 경향이 있다. 또한, 실제 환경에서는 결함 데이터가 정상 데이터에 비해 현저히 적은 클래스 불균형 문제가 존재하여 모델 학습을 어렵게 한다.

1.3 연구 목표 및 기여

본 연구의 목표는 스마트폰 도메인에서 발생하는 미세 결함을 정확히 탐지하기 위해 Anomaly-OV의 핵심인 LTFM 모듈을 효과적으로 파인튜닝하는 것이다.

주요 기여는 다음과 같다.

- 1. 생성형 AI 기반 데이터 증강:** Gemini를 활용하여 미세 기스, 번인 등 수집이 어려운 결함 이미지와 부족한 정상 이미지를 대량 생성하여 데이터 부족 및 불균형 문제를 해결하였다.
- 2. 도메인 특화 파인튜닝:** 생성된 데이터를 포함하여 LTFM 모듈을 학습시킴으로써, 기존 모델이 놓치던 미세 결함에 대한 재현율(Recall)과 정밀도(Precision)를 모두 향상시켰다.
- 3. 일반화 성능 검증:** 학습 데이터(2017~2023년 기종)와 테스트 데이터(2024~2025년 기종)를 분리하여 모델의 일반화 성능을 검증하였다.
- 4. 설명 가능한 이상 탐지 성능 강화:** 도메인에 특화된 LTFM 모듈이 미세 결함이 존재하는 의심 영역을 정확히 포착하여 시각적 근거(Visual Rationale)로 제공함으로써, LLM이 결함의 유무뿐만 아니라 구체적인 양상과 잠재적 원인까지 정확하게 서술하는 추론(Reasoning) 능력을 획기적으로 개선하였다.

2. 관련 연구 (Related Work)

2.1 Anomaly-OV 와 Look-Twice Feature Matching (LTFM)

Anomaly-OV 는 시각적 인코더(Visual Encoder)와 LLM 을 결합한 전문가 모델이다. 이 모델의 핵심은 인간의 시각적 검사 방식인 "전체를 훑어보고(Look Once), 의심스러운 부분을 다시 자세히 보는(Look Twice)" 과정에서 영감을 얻은 **Look-Twice Feature Matching (LTFM)** 메커니즘이다. LTFM 은 시각 인코더(Visual Encoder)가 추출한 특징을 활용하여 다음의 두 단계로 작동한다.

1. **전역 정보 활용 (Global Look):** 원본 이미지의 전역 특징 v_0^o 를 활용하여 객체의 전반적인 정상 및 이상 패턴 분포를 파악한다.
2. **패치 단위 이상 확률 계산 (Local Look):** 시각 인코더의 다계층 특징 맵 v_j^i 에 대하여, 학습 가능한 양성(이상) 임베딩 d_i^+ 과의 유사도를 계산한다. 이를 바탕으로 각 이미지 패치가 이상일 확률을 나타내는 중요도 맵(Significance Map, m_j^i) 을 도출한다.

LTFM 의 핵심 수식은 다음과 같이 정의된다.

$$m_j^i = \frac{\exp\left(\frac{\langle v_j^i, d_i^+ \rangle}{\tau}\right)}{\exp\left(\frac{\langle v_j^i, d_i^+ \rangle}{\tau}\right) + \exp\left(\frac{\langle v_j^i, d_i^- \rangle}{\tau}\right)}$$

여기서 τ 는 온도(temperature) 하이퍼파라미터이며, $\langle \cdot, \cdot \rangle$ 는 코사인 유사도를 의미한다. 산출된 m_j^i 는 이상 가능성이 높은 시각 토큰만을 선별하여 LLM에 전달하는 역할을 수행한다. 이러한 메커니즘 덕분에 LLM은 불필요한 배경 정보에 방해받지 않고 이상 부위에 집중하여 정확한 탐지 및 원인 설명을 수행할 수 있다.

2.2 기존 연구 대비 본 연구의 차별점

기존 연구들은 부족한 결함 데이터를 보완하기 위해 합성 데이터를 활용하거나(APRIL-GAN 등), LLM의 추론 성능 향상을 목표로 지시 데이터(instruction data)를 생성하는 접근(AnomalyGPT)을 주로 취해 왔다. 그러나 시각적 토큰을 선별하는 핵심 모듈(Selector)을 도메인 특화 데이터로 직접 최적화(fine-tuning) 하는 시도는 매우 제한적이었다. 본 연구는 이러한 공백을 보완하며 다음과 같은 차별성과 기여를 갖는다.

스마트폰 결함에 최적화된 LTFM 파인튜닝 기존 연구가 LLM 파라미터 조정 또는 분류기(Classifier) 학습에 집중한 것과 달리, 본 연구는 MLLM 내부에서 ‘무엇을 볼지(What to Look)’를 결정하는 LTFM 모듈을 스마트폰 특화 데이터로 직접 파인튜닝하였다. 이를 통해 모델이 스크래치, 번인, 미세 찍힘 등 스마트폰에서 자주 발생하는 초미세 결함 패턴에 더욱 민감하게 반응하도록 시각적 주의 메커니즘을 재정렬하였다.

Gemini 3 기반 초정밀 합성 결함 생성 스마트폰 액정의 번인(burn-in), 미세 스크래치, 미세 표면 손상과 같이 기존에는 데이터 수집이 거의 불가능했던 희소 및 고난도 결함(hard-to-obtain defects)에 대해, 본 연구는 Gemini 3를 활용하여 실제 촬영으로는 확보할 수 없던 새로운 결함 유형의 학습 이미지를 대규모로 생성하였다. 이를 통해 단순한 데이터 증강을 넘어, 실제 데이터로는 충족시킬 수 없었던 희소 클래스의 표본 수를 충분히 보완하여 클래스 불균형(class imbalance)을 구조적으로 개선할 수 있었다.

기종 간 일반화 능력 검증 (Cross-Model Generalization) 본 연구는 2017–2023년 출시된 다양한 스마트폰 기종으로 학습하고, 2024–2025년 최신 기종으로 테스트하는 실험 설계를 도입하였다. 이러한 구조를 통해 기기 형태, 재질, 화면 구조, 광학 특성 등이 변화하는 실제 산업 환경에서도 모델이 높은 강건성(robustness)을 유지함을 확인하였다.

탐지와 추론의 동시 향상 구조 제시 본 연구에서 수행한 LTFM 파인튜닝은 단순히 탐지 정확도 향상에 그치지 않고, 정확하게 선별된 시각적 근거(visual evidence)를 제공함으로써 LLM의 결함 설명(reasoning) 품질 또한 크게 개선하였다. 이는 Anomaly-OV가 지향하는 설명 가능한 이상 탐지 체계의 실용 가능성을 한층 높이는 성과이다.

3. 방법론

3.1 데이터셋 구축 및 증강

본 연구는 스마트폰 도메인에 특화된 데이터셋을 두 가지 방식으로 구축하였다.

1. 실제 데이터 수집 (Real Data): 중고 거래 플랫폼, 신제품 판매 플랫폼, 공개 벤치마크 데이터셋 등 다양한 출처로부터 스마트폰 이미지를 수집하였다. 우선, 중고나라, 당근마켓, 폰가비와 같은 국내 중고 거래 플랫폼에서 실제 사용자들이 판매를 위해 게시한 이미지를 확보하였다. 이들 플랫폼의 이미지에는 액정 파손, 전면 유리 균열, 모서리 찍힘,

하우징 파손 등 육안으로 쉽게 식별 가능한 중고강도 결함이 다수 포함되어 있어, 실제 산업 환경에서 관측되는 결함 분포를 잘 반영한다는 장점이 있다. 정상(class normal) 데이터의 경우, 쿠팡에서 판매되는 신제품 스마트폰의 사용자 리뷰 이미지를 중심으로 수집하였다. 리뷰 기반 이미지에는 생활 기스나 파손 없이 정상 상태의 스마트폰 외관이 명확하게 촬영된 사진이 풍부하게 포함되어 있어, 결함 탐지 모델의 정상 패턴 학습에 적합하다. 또한, 본 연구는 Mobile Phone Defect Segment Dataset(출처: *Kaggle, ICASSP FDSNeT*)과 같은 기존 공개 벤치마크 데이터셋도 함께 활용하였다. 해당 데이터셋은 스마트폰 화면의 스크래치, 얼룩, 태생적 결점 등 다양한 결함 유형이 정밀하게 라벨링되어 있어, 실데이터 기반 수집 이미지와 결합하였을 때 결함 다양성(diversity) 및 도메인 일반화 성능을 향상시키는 데 기여한다.



(좌) FONGABI 결함 데이터



(우) COUPANG 정상 데이터



2. 생성형 데이터 구축 (Generative Data): 실제 수집된 데이터만으로는 미세 기스(hairline scratch), 번인(burn-in), 미세 찍힘(tiny dent)과 같은 결함(minor defects)의 표본 수가 절대적으로 부족하였다. 또한 비정상 데이터의 양에 비해 정상 데이터가 부족한 문제가 존재하였다. 이러한 한계를 극복하기 위해 본 연구는 Gemini3 기반 생성형 모델을 활용하여 스마트폰 도메인에 최적화된 합성 결함 이미지를 대량 생성하였다. 특히, 생성형 모델이 결함의 형태, 질감, 조명 패턴을 실제 촬영 상황과 일치시키도록 하기 위해, 본 연구는 프롬프트 세분화(Prompt Engineering) 전략을 도입하였다. 이를 통해 실제 데이터에서는 거의 얻을 수 없었던 희소 결함(hard-to-obtain defects)을 안정적으로 생성할 수 있었으며, 모델이 False Positive을 일으키기 쉬운 Hard Negative 샘플 또한 충분히 확보할 수 있었다. 생성된 합성 데이터는 희소 결함 클래스의 표본 수를 대폭 확장하여 클래스 균형을 개선하고, 실제 데이터 기반 학습으로는 얻기 어려운 고난도 결함 인식 능력(hard defect recognition)을 모델이 학습할 수 있도록 도왔다.



Gemini3을 통해 생성한 정상 이미지



Gemini3을 통해 생성한 결함 이미지

본 연구에서 사용한 생성 프롬프트는 시각적 결함 패턴의 재현성을 높이기 위해 결함 유형, 강도, 위치, 조명 조건, 배경 정보 등을 세부적으로 제어할 수 있도록 설계하였다. 아래는 합성 데이터를 생성하기 위해 사용한 대표적인 Prompt 예시이다.

정상(Hard-Negative) 이미지 생성 Prompt

“Generate a clean, undamaged smartphone screen with no scratches, no cracks, and no surface defects. Ensure realistic lighting, reflections, and background to resemble real user-uploaded photos.”

미세 스크래치(hairline scratch) 생성 Prompt

“Create a high-resolution close-up image of a smartphone display under soft indoor lighting. Add

several thin, hairline scratches that are only visible under angled light reflection. The scratch should appear realistic, shallow, and slightly irregular.”

미세 찍힘(tiny dent) 생성 Prompt

“Produce a macro photograph of a smartphone front glass with a tiny dent near the edge. The dent should be less than 1 mm wide, with realistic depth and light distortion around the impact point.”

3.2 데이터 분할 전략

본 연구는 모델이 학습 단계에서 접하지 못한 새로운 기종이나 디자인 변화에 대해 얼마나 강건(robust)하게 작동하는지 평가하기 위해, 스마트폰 기종의 출시 연도를 기준으로 데이터를 분할하는 전략을 채택하였다. 이는 과거의 데이터로 학습된 모델이 미래에 출시될 신제품을 검사해야 하는 실제 산업 현장의 QC 시나리오를 반영한 것으로, 모델의 교차 세대 일반화(Cross-generation Generalization) 성능을 엄격하게 검증하기 위함이다. 평가의 객관성과 공정성을 확보하기 위해 **Gemini 3를 통해 생성된 합성 데이터(Generative Data)는 오직 학습(Train) 및 검증(Validation) 단계에만 제한적으로 활용**하였다. 즉, 테스트(Test) 데이터셋은 100% 실제(Real) 이미지로만 구성하여, 모델이 합성 데이터를 통해 학습한 결함의 특징 표현(Feature Representation)을 실제 환경의 이미지에 얼마나 효과적으로 전이(Transfer)하여 추론할 수 있는지 측정하도록 설계하였다.

구체적인 데이터셋의 통계 및 구성은 Table 1과 같으며, 상세 분할 기준은 다음과 같다.

1. **Train 및 Validation Set (2017~2023년 기종):** 학습 및 검증 데이터는 2017년부터 2023년 사이에 출시된 구형 및 준신형 스마트폰 기종의 이미지로 구성된다. 3.1절에서 언급한 바와 같이, 클래스 불균형과 데이터 부족 문제를 해결하기 위해 실제 데이터와 생성형 데이터를 혼합하여 구축하였다. 전체 학습용 데이터 중 약 20%를 검증(Validation) 셋으로 무작위 할당하여 학습 과정에서의 하이퍼파라미터 튜닝 및 과적합(Overfitting) 방지에 활용하였다.
2. **Test Set (2024~2025년 기종):** 테스트 데이터는 학습 데이터에 포함되지 않은 2024년 이후 출시된 최신 기종의 실제 이미지로만 구성된다. 이는 모델이 학습 과정에서 본 적이 없는 기종에 대한 성능을 평가하는 척도가 되며, 생성형 데이터 없이 실제 이미지만을 사용함으로써 제안하는 모델의 실무 적용 가능성을 검증한다.

최종적으로 구축된 데이터셋은 총 1,706장의 이미지로 구성되며, 학습(Train), 검증(Validation), 테스트(Test) 셋은 각각 1,049장, 263장, 394장으로 배분되었다.

Split	Class	Data Source	Description	Images	Total
Train	Normal	Real	Coupang Reviews (New Products)	337	587
	Normal	Generative	Gemini 3 (Hard Negatives)	250	
	Abnormal	Real	Used Markets & Benchmarks (Cracks, Dents)	262	462
	Abnormal	Generative	Gemini 3 (Fine Scratches, Burn-in)	200	
Validation	Normal	Real	Coupang Reviews	87	147
	Normal	Generative	Gemini 3	60	
	Abnormal	Real	Used Markets & Benchmarks	66	116
	Abnormal	Generative	Gemini 3	50	
Test	Normal	Real	2024-2025 New Models (Real World)	100	100
	Normal	Generative	–	0	
	Abnormal	Real	2024-2025 New Models (Real World)	294	294
	Abnormal	Generative	–	0	
Total	–	–	–	–	1706

Table1. constructed smartphone defect dataset

3.3 모델 학습 및 파인튜닝 (Fine-Tuning Strategy)

스마트폰 도메인의 미세 결함을 효과적으로 탐지하기 위해, Anomaly-OV의 2단계 학습 전략 중 ‘Anomaly Expert’ 부분을 파인튜닝하였다. 사전 학습된 Vision Tower가 가진 범용적인 특징 추출 능력은 유지하되, LTFM(Look-Twice Feature Matching) 모듈과 헤드(Head) 부분이 스마트폰 액정의 미세 기스나 번인과 같은 도메인 특화 결함 패턴을 학습하도록 설계하였다.

1. 네트워크 동결 및 학습 파라미터 설정

학습의 효율성과 기존 지식의 보존을 위해 시각 인코더(Vision Tower)의 가중치는 모두 동결(Freeze)하였다. 코드는 다음과 같은 학습 전략을 반영한다.

- **Frozen Backbone:** `vt.parameters()`에 대해 `requires_grad_(False)`를 적용하여, 대규모 데이터셋으로 사전 학습된 시각적 특징 추출 능력이 학습 과정에서 손실되는 것을 방지하였다. 이는 모델이 스마트폰의 일반적인 형상(Global Feature)과 세부적인 텍스처(Local Feature)를 안정적으로 추출하게 돕는다.
- **Trainable Modules:** 오직 anomaly expert 모듈 내의 LTFM 레이어와 Classifier Head만이 학습 모드로 설정되어 Backpropagation을 수행한다. 이를 통해 모델은 시각

인코더가 추출한 $ov_image_features$ (전역 특징)와 4개 레벨의 $sig_multi_level_features$ (중간 계층 특징)를 입력받아, 결함 유무를 판별하는 최적의 가중치를 학습한다.


2. 손실 함수 (Loss Function) 및 최적화

이상 탐지 문제는 정상과 비정상을 구분하는 이진 분류 문제로 귀결된다. 본 연구에서는 모델의 출력값 분포에 따라 유동적으로 손실 함수를 적용하는 전략을 취하였다.

- **Binary Cross Entropy (BCE):** 모델의 최종 예측값이 로짓 형태인지 확률 형태인지에 따라 BCEWithLogitsLoss 또는 BCELoss를 선택적으로 적용하여 학습 안정성을 확보하였다.
- **Optimizer:** 최적화 알고리즘으로는 AdamW를 사용하였다. 학습률(Learning Rate)은 $2e^{-4}$, 가중치 감쇠(Weight Decay)는 $5e^{-4}$ 로 설정하여, 과적합을 방지하면서도 미세한 결함 특징을 포착할 수 있도록 파라미터 업데이트를 제어하였다.

3. 학습 파이프라인

학습은 총 5 Epoch 동안 진행되었으며, 배치 크기는 8로 설정하였다. 매 Epoch가 종료될 때마다 검증 데이터셋(Validation Set)을 통해 모델을 평가하고, F1-score가 갱신될 때마다 최적의 가중치(best_f1)를 저장하는 Best Model Selection 방식을 채택하였다.



Anomaly-OV 모델의 LTFM Layer

3.4 Threshold 결정 기준

이상 탐지 모델은 각 이미지에 대해 0과 1 사이의 연속적인 ‘이상 점수(Anomaly Score)’를 출력한다. 이를 실제 품질 관리(QC) 현장에 적용하기 위해서는 정상(Normal)과 불량(Abnormal)을 명확히 구분하는 최적의 임계값(Threshold, τ) 설정이 필수적이다. 일반적으로 F1-score를 최대화하는 임계값을 선택하지만, 이는 불균형한 데이터셋에서 정밀도(Precision)나 재현율(Recall) 중 한쪽으로 치우친 결과를 초래할 위험이 있다. 스마트폰 품질 검수 공정의 특성상, 실제 불량을 놓치는 것(False Negative)은 치명적이며, 동시에 과도한 오검출(False Positive)은 재검수 비용을 증가시킨다. 따라서 본 연구에서는 두 지표의 균형을 보장하기 위해 Pareto Filtering과 Max-Min 전략을 결합한 최적화 기법을 제안한다.

1. 임계값 후보 생성 및 성능 측정

검증 데이터셋(Validation Set)에 대한 추론을 수행하여 모든 이미지의 이상 점수 S_{val} 와 정답 레이블 Y_{val} 을 수집한다. 이후 0.0부터 1.0까지 0.001 간격으로 생성된 1,000개의 임계값 후보군 T 에 대해 각각 정밀도(P), 재현율(R), F1 점수를 계산한다.

2. 파레토 필터링 (Pareto Filtering)

단순히 F1 점수가 높은 해를 찾는 대신, 다목적 최적화(Multi-objective Optimization) 관점에서 열등한 해를 제거하는 파레토 필터링을 선행한다. 특정 임계값 T_A 가 다른 임계값 T_B 에 비해 P, R, F1 세 가지 지표가 모두 낮거나 같다면, T_A 는 T_B 에 의해 지배(Dominated)되었다고 판단하고 후보군에서 제거한다. 이를 수식으로 나타내면 다음과 같다.

$$\text{Dominated}(\tau_i) \iff \exists \tau_j \in T, \quad (P_j \geq P_i) \wedge (R_j \geq R_i) \wedge (F1_j \geq F1_i) \wedge (\text{One of them is strictly greater})$$


이 과정을 통해 어떤 지표에서도 다른 임계값보다 우월하지 못한 ‘비효율적 임계값’들을 모두 제거하고, 파레토 최적(Pareto Optimal)에 해당하는 후보군만을 남긴다. 이들은 정밀도와 재현율 사이에 트레이드오프(Trade-off) 관계가 명확한 임계값들의 집합이다.

3. Min-Max 균형 선택 (Max-Min Selection)

축소된 파레토 후보군 P 중에서 최종 임계값 τ^* 를 선정하기 위해, 정밀도와 재현율 중 더 낮은 값 $\min(P, R)$ 을 최대화하는 전략을 사용한다. 이는 모델 성능의 하한선(Lower Bound)을 끌어올리는 방식이다.

$$\tau^* = \underset{\tau \in P}{\operatorname{argmax}} (\min(\text{Precision}(\tau), \text{Recall}(\tau)))$$

이 기준은 F1-score 최대화 방식이 간과할 수 있는 지표 간의 불균형을 방지한다. 예를 들어, 재현율이 99%이고 정밀도가 60%인 경우 F1 점수는 높게 나올 수 있으나, 이는 현장에서 과도한 가성 불량을 유발한다. 반면, 본 연구의 제안 방식은 P와 R이 모두 균형 있게 높은 지점을 선택하도록 강제한다. 결과적으로, 이 방식은 스마트폰 미세 결함 탐지와 같이 오검출과 미검출의 패널티가 모두 높은 도메인에서 가장 강건(Robust)하고 신뢰할 수 있는 결정 경계를 제공한다. 본 연구의 실험 결과에서도 해당 방식은 단순 F1 최대화 방식 대비 정밀도와 재현율의 편차를 줄여, 실제 운영 환경에 가장 적합한 성능을 보여주었다.



	Criterion	Precision (%)	Recall (%)	F1 (%)	P-R (%)
0	Best F1	100.00	98.28	99.13	1.72
1	Pareto + min(P,R)	98.29	99.14	98.71	0.85

Table 2. Best Threshold 선정 기준 : F1 vs Pareto Filtering + Min(P,R) Selection

4. 실험 및 결과

4.1 실험 환경 및 평가 지표

실험 환경 및 모델 설정

실험은 Anomaly-OV 모델의 기본 설정을 따랐으며, LTFM 모듈의 파인튜닝에 초점을 맞추었다. 학습에는 COLAB A100 GPU 환경을 사용하였다.

평가 지표

결함 탐지 성능의 객관적인 비교를 위해 Accuracy(정확도), Precision(정밀도), Recall(재현율), F1-score의 네 가지 지표를 사용하였다. 특히 결함 탐지 문제의 특성상, 정밀도와 재현율의 조화 평균이며 전체 성능을 대표하는 F1-score를 주 지표로 선정하였다.

평가 시나리오

모델의 학습 데이터 구성에 따른 성능 변화를 분석하기 위해 세 가지 시나리오를 설정하여 테스트 데이터셋(2024~2025년 최신 기종, Real Data 100%)에 대한 성능을 측정하였다.

시나리오	학습 데이터 구성	주요 목적
(Base) Pretrained Model	원본 모델 파라미터 (파인튜닝 없음)	도메인 적응 전 성능 기준점 설정
Fine-Tuning (Real Data Only)	실제 수집 데이터만 사용	LTFM 모듈의 일반적인 도메인 적응 효과 확인
Fine-Tuning (Real + GenAI)	실제 데이터 + Gemini 3 생성 데이터	생성형 데이터가 희소 결함 학습에 기여하는 효과 검증


Table 3. 성능 변화 분석을 위한 3가지 시나리오

4.2 정량적 평가 결과 (Quantitative Results)

세 가지 시나리오(Base 모델, 실데이터 파인튜닝, 생성형 데이터 포함 파인튜닝)에 대한 성능 비교 결과는 Table 4와 같다.

Model Configuration	Threshold	Accuracy	Precision	Recall	F1-score
(Base) Pretrained Model	0.6070	79.70%	96.52%	75.51%	84.73%
Fine-Tuning (Real Data Only)	0.8750	82.99%	97.89%	78.91%	87.38%
Fine-Tuning (Real + GenAI)	0.4250	84.26%	97.54%	80.95%	88.48%

Table 4. 스마트폰 도메인 이상 탐지 성능 비교



베이스라인 및 파인튜닝 효과 분석

- (Base) Pretrained Model: 파인튜닝을 거치지 않은 사전 학습 모델은 F1-score 84.73%를 기록하였다. 정밀도(P, 96.52%)는 높았으나, 재현율(R, 75.51%)이 상대적으로 낮게 나타났다. 이는 모델이 일반적인 산업 데이터에 맞춰 학습되었기 때문에 스마트폰의 미세 기스나 번인과 같은 도메인 특화 미세 결함을 정상으로 오분류(False Negative)하는 경향이 강함을 시사한다.
- Fine-Tuning (Real Data Only): 실제 데이터만으로 LTFM 모듈을 파인튜닝한 결과, F1-score는 87.38%로 상승하였다. 이는 LTFM 모듈이 도메인 적응 학습을 통해 미세 결함에 대한 민감도를 일부 높였음을 의미한다. 그러나 재현율(R, 78.91%)의 개선 폭은 여전히 제한적이었다.

2. 생성형 데이터 증강 효과 (Real + GenAI)

- Fine-Tuning (Real + GenAI): Gemini 3 생성 데이터를 포함하여 학습한 모델은 모든 시나리오 중 가장 우수한 F1-score 88.48%를 달성하였다.
- 재현율의 비약적 상승: 이 모델은 특히 재현율이 80.95%로 크게 향상되었는데, 이는 생성형 데이터가 실제 수집이 어려웠던 미세 기스나 번인과 같은 탐지 고난도 결함 유형을 모델에게 효과적으로 학습시켰음을 의미한다. 재현율의 상승은 실제 QC 현장에서 결함을 놓칠 확률(FN)을 크게 줄였음을 나타낸다.
- Threshold 변화: 주목할 점은 최적 임계값이 Base 모델의 0.6070에서 0.4250으로 크게 낮아졌다는 것이다. 이는 모델이 이제 결함의 경계(Decision Boundary)를 더

보수적으로(이상 쪽으로) 판단하더라도, 정밀도(97.54%)를 여전히 높게 유지할 만큼 이상 패턴에 대한 확신이 높아졌음을 시사한다.

결론적으로, 본 연구에서 제안된 생성형 데이터 기반 LTFM 파인튜닝 전략은 스마트폰 도메인에서 발생하는 데이터 불균형 및 미세 결함 탐지 문제를 성공적으로 해결하고, 기존의 베이스라인 모델 대비 향상된 일반화 성능을 입증하였다.

5. 분석 및 고찰

5.1 LTFM 예측 결과 정성적 분석

'Fine-Tuning (Real + GenAI)' 모델의 실효성을 검증하기 위해, 베이스라인 모델인 (Base) Pretrained Model과의 예측 결과를 정성적으로 비교 분석하였다. 특히 정량적 지표의 상승이 실제 결함 이미지에 대한 Visual Attention 변화로 어떻게 이어졌는지, 그리고 여전히 존재하는 오분류(False Negative)의 원인은 무엇인지 분석하였다.

미세 결함 탐지 성능의 개선 (Improvements in Micro-Defect Detection) 가장 유의미한 변화는 기존 Pretrained Model에서 False Negative(미검출)로 분류되던 '미세 결함'들이 제안된 모델에서 True Positive로 정확히 전환되었다는 점이다. 베이스라인 모델은 일반적인 산업 데이터셋(MVTec AD 등)에 편향되어 있어, 스마트폰 표면의 **미세 찍힘(Tiny Dent)**, **미세 기스(Hairline Scratch)**, **미세 파임**과 같은 초미세 패턴을 배경 노이즈(Background Noise)로 간주하는 경향이 있었다. 그러나 Gemini 3를 통해 생성된 고난도 결함 데이터를 포함시킨 Data로 LTFM 모듈을 파인튜닝한 결과, 모델은 이러한 미세 패턴을 명확한 '이상 특징 (Anomaly Feature)'으로 학습하게 되었다. 그 결과, 육안으로도 식별이 어려운 수준의 얇은 스크래치나 모서리 찍힘 영역에 대해 Anomaly Map이 강하게 활성화(Activation)됨을 확인하였다. 이는 생성형 데이터 증강이 희소 결함에 대한 모델의 특징 표현(Feature Representation) 능력을 실질적으로 강화했음을 입증한다.

FN | score=0.409 61971943864375601_up_1752911638.jpeg FN | score=0.371 08626733152424787_down_1759287101.jpeg FN | score=0.410 08626733152424787_up_1759287101.jpeg



(Base) Pretrained Model에서 False Negative인 Case

Anomaly Map
Pred Score: 0.9042



Anomaly Map
Pred Score: 0.9955



Anomaly Map
Pred Score: 0.9295



Base Model에서 False Negative였던 Case의 Fine-Tuning (Real + GenAI) 예측 결과

잔존하는 한계 및 원인 분석 (Limitations and Failure Analysis) 성능 향상에도 불구하고, 일부 테스트 케이스에서 여전히 False Negative가 발생하는 원인을 분석한 결과, 다음과 같은 세 가지 주요 요인을 도출하였다.

- **학습 데이터에 부재한 결함 유형 (Unseen Defect Types):** 모델은 학습 데이터에 포함되지 않은 케이스 자국이나 지문 자국과 같은 오염 유형을 결함으로 인식하지 못하는 한계를 보였다. 이는 모델이 '기스'나 '파손'의 형태학적 특징은 학습했으나, '오염'에 대한 클래스 정보는 학습하지 못했기 때문이다. 이는 LTFM이 본질적으로 학습된 분포 내의 이상 패턴에 민감하게 반응하기 때문이며, 향후 연구에서 Gemini를 활용하여 다양한 오염 및 이물질 데이터를 추가 생성하고 학습시킴으로써 해결 가능할 것으로 판단된다.
- **이미지 품질 저하로 인한 특징 소실 (Image Quality Dependency):** 입력 이미지의 해상도가 낮거나 초점이 맞지 않는 경우, 탐지 성능이 급격히 저하되는 현상이 관측되었다. 미세 결함 탐지는 픽셀 단위의 급격한 변화를 포착하는 것이 핵심인데,

저화질 이미지에서는 이러한 텍스처 정보가 소실되어 모델이 결함을 표면의 질감으로 오인하거나 무시하게 된다. 이는 고해상도 촬영 환경이 전제되어야 하는 비전 검사 시스템의 물리적 제약 사항으로 해석된다.

- **기능적 결함과 시각적 결함의 괴리 (Gap between Visual and Functional Defects):** 특기할 만한 실패 사례로, 액정 패널의 고장으로 인해 화면이 반만 켜지는 경우가 관측되었다. 제안된 모델은 이를 결함으로 탐지하지 못하고 정상으로 분류하였는데, 이는 해당 현상이 물리적인 표면 손상(스크래치, 깨짐)을 동반하지 않는 기능적 상태이기 때문이다. 비전 모델 입장에서는 꺼져 있는 검은 화면 영역이 '깨끗한 표면'과 시각적으로 유사한 특징을 가지므로 이를 이상으로 판단하기 어렵다. F1점등 테스트 등 기능 검사 프로세스와의 결합이 필요함을 시사한다.



Fine-Tuning (Real + GenAI) Model에서 False Negative인 Case

5.2 탐지 성능 향상에 따른 추론(Reasoning) 능력 개선

본 연구에서는 LTFM 기반 이상 탐지 성능이 MLLM 기반 품질 보고서 생성에 어떤 질적 차이를 만들어 내는지 분석하였다. Anomaly-OV가 출력한 Anomaly Score와 Bounding box 정보를 시각 입력과 함께 MLLM에 제공하고 스마트폰 전면부에 대한 품질 보고서를 한국어로 생성하도록 하여 탐지-추론 파이프라인의 연동 효과를 평가하였다.

프롬프트 설계 모델이 수행해야 할 역할과 출력 형식을 통제하기 위해 공통 System Prompt를 정의했다. System Prompt에서는 모델의 역할을 스마트폰 전면부 품질 검사 전문가로 지정하고, 출력 형식을 고정하였다. 또한 이미지와 메타데이터로부터 합리적으로 지지가 되지 않는 결함 서술은 자연스럽게 억제되도록 설계했다. 최종 System Prompt문은

아래와 같다.

System Prompt

“You are an expert visual quality inspector for smartphone front screens. Given an input image (and optionally anomaly-related metadata), you must write a structured quality report in Korean with the following format:

First line: “품질 보고서”

Second line: “Anomaly Score: [숫자]”

Third line: “Model prediction: [Normal/Abnormal]”

Section 1: “1. 종합 평가” — 전체적인 외관 상태와 주요 결함을 2-4문장으로 요약

Section 2: “2. 결함 위치 및 유형” — 번호를 붙여 결함 위치, 형태, 영향도를 기술

Use concise, formal Korean. Describe only defects that can be reasonably supported by the visual evidence or metadata.

User Prompt는 두 실험 조건에 동일한 기본 구조를 갖도록 설계하였다. 공통 User Prompt는 입력으로 스마트폰 전면 이미지와 이상 점수, 모델 예측이 주어지며 화면 전체를 관찰해 결함을 찾고 결함의 위와 유형 등을 구체적으로 서술하라는 지시를 포함한다. 최종 User Prompt문은 아래와 같다.

User Prompt

“You are given: A smartphone front-screen image. An anomaly score and model prediction from an anomaly detection model.

Use the following metadata: Anomaly Score: {anomaly_score} Model prediction: {model_prediction}

Instructions: Inspect the entire front screen surface and identify any defects you can observe from the image. Describe only defects that are visually plausible based on the image and metadata. Be explicit about where the defect is located (e.g., relative position on the screen) and what type of surface damage it appears to be (scratch, spot, crack, etc.).

Now write the quality report in Korean in the following exact format:

품질 보고서

Anomaly Score: {anomaly_score}

Model Prediction: {model_prediction}

1. 종합 평가 (2-4문장으로 전체적인 외관 상태와 주요 결함을 요약한다.)

2. 결함 위치 및 유형

[결함 #1] ...

[결함 #2] ... (필요한 경우에만).

두 설정의 유일한 차이는 bounding box(ROI) 정보 제공 여부에만 두었다. 첫 번째 버전은

ROI-guided 버전으로 공통 User prompt 뒤에 이미지 위에 바운딩 박스를 추가로 표시되어 있으며 이는 이상 탐지 모델이 잠재적 결함 후보로 판단한 영역(ROI)을 의미한다는 것을 알리고 각 ROI 내부를 더 꼼꼼하게 관찰하는 문단을 추가하였다. 다만 최종적으로는 여전히 이미지와 메타데이터로부터 합리적으로 지지할 수 있는 결함만을 보고서에 포함하도록 해 ROI가 정답을 직접 암시하지 않도록 하였다. 반면, 두 번째 버전은 Image-only 버전으로 동일한 System Prompt와 공통 User Prompt를 사용하되 ROI 관련 추가 문단을 포함하지 않고 바운딩 박스가 없는 원본 이미지만 입력으로 제공했다. 이와 같은 설계를 통해 두 설정 간 차이가 프롬프트 구조나 서술 정책의 변화가 아니라 탐지 모델이 제공해 주는 추가 시각 단서(ROI)의 존재 여부에서만 발생하도록 통제하였다. 최종 ROI of User Prompt문은 아래와 같다.

ROI of User Prompt

Additionally, some rectangular bounding boxes are overlaid on the image. These bounding boxes indicate regions of interest (ROI) where the anomaly model suspects potential defects. Carefully and thoroughly inspect the inside of each ROI, as these areas are statistically more likely to contain subtle defects. However, still report only those defects that you judge as visually plausible based on the image; if an ROI appears normal (e.g., only reflection or lighting), you may consider it as “no defect” in your final description.

실험에는 동일한 이미지를 사용한 상태에서 바운딩 박스가 포함된 이미지와 ROI 문단이 포함된 프롬프트 사용한 버전(ROI-guided)과 바운딩 박스가 제거된 원본 이미지와 함께 공통 프롬프트를 사용한 버전(Image-only)으로 하여 두 설정에서 각각 MLLM에게 품질 보고서 생성을 수행하고, 생성 결과를 정성적으로 비교하였다.

탐지-추론 연동 효과 및 시사점

두 설정 모두 모델은 이상 점수에 기반해 스마트폰을 Abnormal로 판단하고 전면 좌측의 큰 손상을 주요 결함으로 기술하였다. 하지만 중앙부 미세 스크래치에 대한 처리에서 뚜렷한 차이가 나타났다. ROI-guided 설정에서는 바운딩 박스로 표시된 영역을 추가로 집중 관찰한 결과, 화면 중앙부의 얇은 스크래치를 실제 결함으로 인식하고 화면 정중에서 약간 오른쪽 영역의 미세 스크래치와 같이 위치, 형태, 영향도를 비교적 구체적으로 서술하였다. 일부 ROI에 대해서는 조명 반사나 노이즈로 판단하여 의심 영역이었으나 이상 없음으로 판정하는 등 탐지 결과를 비판적으로 해석하는 양상도 관찰되었다. 반면 Image-only 설정에서는 동일한 이미지에 대해 좌측 큰 손상만 보고서에 포함하고 중앙부 미세 스크래치는 언급되지 않았다. 프롬프트 구조는 동일하지만 추가적인 ROI 정보가 주어지

지 않은 상태에서는 중앙부의 희미한 패턴이 시각적으로 타당한 결함으로 판단되기 어려웠던 것으로 해석할 수 있다. 품질 보고서에 대한 결과는 아래 첨부한 사진과 같다.

SmartPhone with bounding box



Anomaly Score: 0.9989
Prediction: Abnormal



System prompt

You are an expert visual quality inspector for smartphone front screens.

Given an input image (and optionally anomaly-related metadata), you must write a structured quality report in Korean with the following format:

First line: "품질 보고서"

Second line: "Anomaly Score: [숫자]"

Third line: "Model prediction: [Normal/Abnormal]"

Section 1: "1. 종합 평가" — 전체적인 외관 상태와 주요 결함을 2~4문장으로 요약

Section 2: "2. 결함 위치 및 유형" — 번호를 붙여 결함 위치, 형태, 영향도를 기술

Use concise, formal Korean. Describe only defects that can be reasonably supported by the visual evidence or metadata.

User prompt

You are given: A smartphone front-screen image. An anomaly score and model prediction from an anomaly detection model.

Use the following metadata: Anomaly Score: {anomaly_score} Model prediction: {model_prediction} Instructions: Inspect the entire front screen surface and identify any defects you can observe from the image. Describe only defects that are visually plausible based on the image and metadata. Be explicit about where the defect is located (e.g., relative position on the screen) and what type of surface damage it appears to be (scratch, spot, crack, etc.).

Now write the quality report in Korean in the following exact format:

품질 보고서

Anomaly Score: {anomaly_score}

Model Prediction: {model_prediction}

1. 종합 평가 (2~4문장으로 전체적인 외관 상태와 주요 결함을 요약한다.)

2. 결함 위치 및 유형

[결함 #1] ...

[결함 #2] ... (필요한 경우에만)

Additionally, some rectangular bounding boxes are overlaid on the image. These bounding boxes indicate regions of interest (ROI) where the anomaly model suspects potential defects. Carefully and thoroughly inspect the inside of each ROI, as these areas are statistically more likely to contain subtle defects. However, still report only those defects that you judge as visually plausible based on the image; if an ROI appears normal (e.g., only reflection or lighting), you may consider it as "no defect" in your final description.

System prompt

You are an expert visual quality inspector for smartphone front screens.

Given an input image (and optionally anomaly-related metadata), you must write a structured quality report in Korean with the following format:

First line: "품질 보고서"

Second line: "Anomaly Score: [숫자]"

Third line: "Model prediction: [Normal/Abnormal]"

Section 1: "1. 종합 평가" — 전체적인 외관 상태와 주요 결함을 2~4문장으로 요약

Section 2: "2. 결함 위치 및 유형" — 번호를 붙여 결함 위치, 형태, 영향도를 기술

Use concise, formal Korean. Describe only defects that can be reasonably supported by the visual evidence or metadata.

User prompt

You are given: A smartphone front-screen image. An anomaly score and model prediction from an anomaly detection model.

Use the following metadata: Anomaly Score: {anomaly_score} Model prediction: {model_prediction} Instructions: Inspect the entire front screen surface and identify any defects you can observe from the image. Describe only defects that are visually plausible based on the image and metadata. Be explicit about where the defect is located (e.g., relative position on the screen) and what type of surface damage it appears to be (scratch, spot, crack, etc.).

Now write the quality report in Korean in the following exact format:

품질 보고서

Anomaly Score: {anomaly_score}

Model Prediction: {model_prediction}

1. 종합 평가 (2~4문장으로 전체적인 외관 상태와 주요 결함을 요약한다.)

2. 결함 위치 및 유형

[결함 #1] ...

[결함 #2] ... (필요한 경우에만)

[left] ROI-guided version prompt / [right] Image-only version prompt

품질 보고서

Anomaly Score: 0.9989

Model Prediction: Abnormal

1. 종합 평가

본 이미지는 이상 점수 0.9989로, 기준치를 크게 상회하여 전면부에 복수의 외관 결함이 존재하는 단말기로 판단된다. 모델이 제시한 바운딩 박스(의심 구역)를 기준으로 정밀 관찰한 결과, 전면 좌측 중단부에서 뚜렷한 주요 표면 손상 1건과 화면 중앙 부근에서 일반 육안 검사에서는 놓치기 쉬운 가느다란 “-”형 미세 스크래치 1건이 실제 결함으로 확인되었다. 일부 바운딩 박스 영역은 조명 반사나 이미지 노이즈로 판단되어 결함에서 제외되었으나, 주요 및 미세 결함이 동시에 존재한다는 점에서 무결점(A급) 출하 기준에는 부적합하며 B급 또는 리퍼/리워크 대상으로 분류하는 것이 타당하다. 특히 좌측 손상은 한눈에 보이는 수준으로 외관 신뢰도를 저하시킬 수 있고, 중앙부 미세 스크래치는 프리미엄 단말기 고객의 기대 수준을 고려할 때 추가 관리가 필요한 요소로 평가된다.

2. 결함 위치 및 유형

2-1. [결함 #1] 좌측 중단부 표면 손상 (주요 결함)

- 위치: 전면 화면의 좌측 중앙부
- 형태: 세로 방향으로 비교적 길게 이어진 굽힘/찍힘 혼합 손상
- 특성: 주변 대비 밝기와 질감이 일정하게 깨져 있으며, 조명 각도 변화에도 패턴이 유지되어 실제 물리적 손상으로 판단된다. 일반 사용자가 육안으로도 인지 가능한 수준의 결함으로, 외관 품질 평가 시 주요 감점 요인에 해당한다.
- 영향도: 미관 저하가 뚜렷하고 장기 사용 시 미세 균열 확산 가능성도 있어 프리미엄-무결점 등급에는 적합하지 않다.

2-2. [결함 #2] 화면 중앙부 “-”형 미세 스크래치 (세부 결함)

- 위치: 화면 정중앙에서 약간 오른쪽 영역
- 형태: 짧은 가로 방향 “-” 모양의 헤어라인 스크래치
- 특성: 크기가 작고 조명 조건에 따라 희미하게 보이지만, 바운딩 박스를 기준으로 확대 관찰했을 때 연속적인 선형 손상이 확인된다. 일반적인 육안-기본 촬영만으로는 간과되기 쉬운 미세 결함에 해당한다.
- 영향도: 기능에는 직접적 영향은 없으나, 고가 단말기의 외관 완성도와 고객 만족도에 부정적 요소로 작용할 수 있어 “미세 스크래치 존재” 항목으로 별도 기록이 필요하다.

2-3. [기타 의심 영역] 이상 없음으로 판정

- 내용: 상단 및 하단 일부 바운딩 박스 구역은 확대 관찰 결과 조명 반사, 배경 질감, 이미지 노이즈로 확인되어 실질적인 결함으로 보기는 어렵다. 이는 모델이 넓은 범위의 의심 후보를 제시하고, LLM 기반 보고서에서 최종적으로 결함 여부를 선별-정제하는 데 의미가 있음을 보여준다.

📄 📌 🔄 ↶ ↷ ...

[ROI-guided version Quality report result

품질 보고서

Anomaly Score: 0.8167

Model Prediction: Abnormal

1. 종합 평가

이미지 관찰 결과, 전면 좌측 중단부에 비교적 큰 표면 손상 1건이 명확히 확인되며, 이로 인해 무결점(A급) 출하 기준에는 부적합할 가능성이 높은 단말기로 판단된다.

2. 결함 위치 및 유형

2-1. [결함 #1] 좌측 중단부 표면 손상 (확인된 주요 결함)

- 위치: 전면 화면의 좌측 중앙부
- 형태: 세로 방향으로 비교적 길게 퍼져 있는 스크래치/마찰 자국
- 특성: 주변 영역에 비해 밝기와 질감이 눈에 띄게 달라 보이며, 한 번 이상 강하게 굽히거나 비벼진 흔적으로 추정된다. 일반 사용자도 쉽게 인지 가능한 수준의 시각적 결함으로, 외관 평가 시 명확한 감점 요소에 해당한다.
- 영향도: 제품의 첫인상과 심리적 품질 인식에 부정적 영향을 줄 수 있으며, 프리미엄급-무결점 출하를 목표로 할 경우 재검토 또는 등급 조정이 필요한 수준으로 평가된다.

📄 📌 🔄 ↶ ↷ ...

Image-only version Quality report result

이 결과는 탐지 단계에서 어떤 영역을 이상 후보로 표시 여부가 모델의 추론 결과에 영향을 줄 수 있음을 보여준다. 정량적인 F1-score 향상뿐만 아니라, LTFM이 제공하는 ROI 품질이 좋아질수록 MLLM은 같은 프롬프트 하에서도 더 많은 미세 결함을 발견하고 그 위치, 형태, 영향을 세밀하게 설명할 수 있게 된다.

5.3 생성형 데이터의 효용성

본 연구에서 Gemini를 통해 생성된 데이터는 단순한 data의 수량 증대 이상의 효과를 보였다. 실제 데이터 수집만으로는 확보하기 힘든 '경계선상의 결함(Borderline Defects)'들을 생성하여 학습함으로써, 모델이 정상과 이상의 결정 경계(Decision Boundary)를 더 정교하게 학습할 수 있었다.

6. 결론

6.1. 기대효과

본 연구는 생성형 AI 기반 데이터 증강과 도메인 특화 MLLM 파인튜닝을 결합한 독창적인 접근 방식을 통해 스마트폰 품질 관리(QC) 분야뿐만 아니라 광범위한 산업 영역에 걸쳐 다음과 같은 네 가지 핵심적인 기대 효과를 가져온다.

1. 데이터 희소성 및 불균형 문제 해결의 실질적 방법론 제시

제조업에서 가장 큰 난제 중 하나인 결함 데이터 희소성(Data Scarcity) 및 클래스 불균형(Class Imbalance) 문제를 해결하는 범용적인 파이프라인을 제시한다.

희소 결함 데이터 확보 (Hard-to-Obtain Defects): 실제 환경에서는 수집이 극히 어려운 미세 기스(hairline scratch), 번인(burn-in), 미세 찍힘(tiny dent)과 같은 도메인 특화 미세 결함에 대해 Gemini 3와 같은 생성형 AI를 활용하여 고품질의 합성 이미지를 대량 생성하는 능력을 입증한다. 이는 단순히 데이터의 양을 늘리는 것을 넘어, 실제로는 드물게 발생하는 결함 유형을 모델이 충분히 학습할 수 있도록 결함 다양성(Defect Diversity)을 구조적으로 확장한다.

클래스 불균형 개선: 기존 데이터셋에서 정상 데이터(Normal Class) 대비 비정상 데이터(Abnormal Class)가 현저히 부족했던 불균형 문제를 생성형 데이터를 통해 해소한다. 특히,

프롬프트 엔지니어링을 통해 모델이 오탐(False Positive)을 일으키기 쉬운 Hard Negative 정상 샘플까지 확보함으로써, 모델의 결정 경계(Decision Boundary)를 정교하게 조정하고 학습 안정성을 획기적으로 향상시킨다. 이 파이프라인은 초기 데이터가 부족한 'Cold Start' 문제를 겪는 모든 산업 도메인에 즉시 적용 가능하다.

2. 설명 가능한 지능형 QC 시스템의 정확도 및 품질 향상

Anomaly-OV의 핵심인 Look-Twice Feature Matching (LTFM) 모듈을 도메인 특화 데이터로 파인튜닝함으로써, MLLM 기반 설명 가능한 품질 관리(Explainable Intelligent QC) 시스템의 신뢰성과 실용성을 극대화한다.

탐지 정확도(Detection Accuracy)의 개선: LTFM 모듈이 스마트폰 특화 결함 패턴에 최적화되어, 기존 베이스 모델이 놓치던 미세 결함까지 정확하게 포착하는 능력을 확보한다. 이는 F1-score 88.48%로 정량적으로 입증된다.

추론(Reasoning) 능력의 질적 향상: LTFM이 미세 결함이 존재하는 영역에 정확한 시각적 근거(Visual Rationale)와 Bounding Box를 제공함으로써, LLM은 "화면 중앙 하단에 미세한 긁힘이 관찰된다"와 같이 단순히 불량 유무를 넘어 결함의 종류, 위치, 양상을 구체적인 자연어로 서술할 수 있게 된다. 이는 검사 결과에 대한 인간 검사관의 신뢰도를 높이고 판정의 오차를 줄여, 스마트폰을 넘어 반도체, 자동차 부품 등의 검사 자동화 고도화에 기여할 수 있다.

3. 도메인 특화 임계값 결정 기준 도입을 통한 검수 정책 반영

본 연구는 Pareto Filtering과 Min-Max 전략을 결합한 새로운 임계값(τ) 결정 기준을 제시하여, 기업의 도메인 특화 검수 정책을 모델 성능에 직접적으로 반영할 수 있는 메커니즘을 구축한다.

정밀도(Precision)와 재현율(Recall)의 균형: 일반적인 F1-score 최대화 방식은 한쪽 지표로 치우칠 위험이 있다. 제안된 방식은 $\text{Pareto} + \max\text{-min}(P, R)$ 을 기준으로 임계값을 선정함으로써, 오검출(False Positive)과 미검출(False Negative)의 페널티가 모두 높은 실제 산업 현장에서 가장 강건(Robust)하고 신뢰할 수 있는 결정 경계를 제공한다.

유연한 정책 적용 가능: 이 기준을 활용하면, 특정 산업 분야나 기업이 '재현율을 99%

이상으로 유지해야 한다(결함을 절대 놓치면 안 됨)'와 같이 자신들의 도메인에 맞는 특정 결함 유형에 대한 민감도(Sensitivity) 요구 사항을 충족시키면서도, 정밀도 저하를 최소화하는 최적의 운용 지점을 설정할 수 있다. 이는 기존 공개된 모델로는 불가능했던 '사용자 맞춤형 불량 탐지 기준'의 설정을 가능하게 한다.

4. 교차 세대(Cross-Generation) 일반화 성능 확보

학습 데이터와 테스트 데이터를 스마트폰 기종의 출시 연도(2017~2023년 vs 2024~2025년)를 기준으로 분리하여 평가하는 엄격한 실험 설계를 통해 모델의 강건성(Robustness) 및 일반화 능력을 입증한다.

미래 신제품에 대한 안정적 검사: 학습 과정에서 접하지 못한 새로운 디자인, 재질, 광학 특성을 가진 최신 기종(2024~2025년 출시)에 대해서도 안정적인 탐지 성능을 유지한다. 이는 스마트폰과 같이 제품 세대가 빠르게 변화하는 소비자 가전 시장에서 모델을 매년 재학습할 필요성을 줄여준다.

유지보수 비용 절감: 검증된 교차 세대 일반화 성능은 모델의 유지보수 주기를 장기화하고, 새로운 제품 라인이 도입될 때마다 발생하는 모델 업데이트 및 재학습 비용을 획기적으로 절감하는 실질적인 경제적 효과를 기대할 수 있다.

본 연구는 데이터 생성, 모델 최적화, 임계값 결정, 성능 검증의 전 과정에서 실무적 가치를 창출하며, 도메인 특화 인공지능 품질 관리 분야의 새로운 기준을 제시할 것으로 기대한다.

6.2. 추후 연구 방향

본 연구의 성과를 바탕으로 향후 발전시켜야 할 연구 방향은 다음과 같다.

첫째, 생성된 데이터의 사실성(Realism)에 대한 정량적 평가 지표 개발이 필요하다. 현재는 생성된 데이터가 모델 성능 향상에 기여함을 통해 간접적으로 그 유효성을 입증하였으나, 실제 물리적 결함과 생성된 결함 사이의 분포 차이(Domain Gap)를 줄이기 위해 FID(Fréchet Inception Distance)와 같은 지표를 도메인에 맞게 변형하여 평가하고, 이를 피드백하여 생성 품질을 높이는 연구가 수행되어야 한다.

둘째, 실시간 추론을 위한 모델 경량화 연구이다. Anomaly-OV와 같은 MLLM 기반 모델

은 높은 연산량을 요구하여 고속으로 진행되는 컨베이어 벨트 라인에 실시간 적용하기에는 제약이 있다. 따라서 LTFM의 핵심 탐지 능력은 유지하면서 LLM의 크기를 줄이는 지식 증류(Knowledge Distillation) 기법이나 양자화(Quantization) 기술을 적용하여 추론 속도를 최적화하는 연구가 필요하다.

셋째, 다양한 도메인으로의 확장성 검증이다. 본 연구는 스마트폰 외관 결함에 집중하였으나, 향후에는 X-ray나 CT와 같은 비파괴 검사(NDT) 이미지나 3D 포인트 클라우드 데이터 등 다양한 모달리티로 확장하여, 제안된 생성형 파인튜닝 프레임워크가 범용적인 제조 이상 탐지 방법론(Unified Manufacturing Anomaly Detection)으로 자리 잡을 수 있도록 연구를 확장할 계획이다.

7. 소스 코드

프로젝트 Github 링크 : <https://github.com/olchan/DataAnalysisCapstoneDesign>

8. 참고문헌

- [1] J. Xu, S.-Y. Lo, B. Safaei, V. M. Patel, and I. Dwivedi, "Towards Zero-Shot Anomaly Detection and Reasoning with Multimodal LLMs," arXiv preprint arXiv:2502.07601, 2025.
- [2] H. Liu, C. Li, Q. Wu, and Y. J. Lee, "Visual Instruction Tuning," in NeurIPS, 2023.
- [3] B. Li et al., "LLaVA-OneVision: Easy Visual Task Transfer," arXiv preprint arXiv:2408.03326, 2024.
- [4] A. Radford et al., "Learning Transferable Visual Models from Natural Language Supervision," in ICML, 2021.
- [5] OpenAI, "GPT-4 Technical Report," arXiv preprint arXiv:2303.08774, 2023.
- [6] Z. Gu et al., "AnomalyGPT: Detecting Industrial Anomalies using Large Vision-Language Models," in AAAI, 2024.
- [7] X. Chen, Y. Han, and J. Zhang, "APRIL-GAN: A Zero-/Few-Shot Anomaly Classification and Segmentation Method," in CVPR Workshop, 2023.
- [8] X. Zhang et al., "RealNet: A Feature Selection Network with Realistic Synthetic Anomaly for Anomaly Detection," in CVPR, 2024.